解釈可能な深層ベクトル自己回帰による グレンジャー非因果推定

栗田 煌矢
東北大学経済学部 李研究室

概要

非線形な多変量時系列の依存構造と関係の方向を記述するため、入力依存係数と構造ゲートを持つ GSE-VAR を提案する。係数生成の入力と出力を共通ゲートで選択し、全ラグのゲートが 0 なら推定モデルの予測がその系列に依存しないことを示す。各経路を Bernoulli ゲートで表し、選択確率の和に罰則を課す期待 L0 正則化と、DisARM による不偏勾配推定を用いて学習する。独立な予備系列で設定を選んだ Lorenz96 では、系列長 250 の平均 F1 が 0.997 となり、系列長 500 では全 5 系列で参照構造を回復した。線形 VAR の系列長 500 では平均符号 BA0.975 を得た。付録では Favorita の 12 商品カテゴリに適用する。検証 MSE で選んだモデルは 7 本の非自己辺を選択し、標準化尺度のテスト MSE は 0.4620 であった。選択した経路を、観測条件下の予測依存として記述する。

1　序論

経済活動や需要の多変量時系列では、他の情報を条件とした予測上の必要性から系列間の関係を調べるグレンジャー因果分析が用いられる (Granger, 1969)。線形ベクトル自己回帰（VAR）は係数から関係を読めるが、非線形モデルでは入力が予測に関与する複数の経路を制御する必要がある。

この課題に対し、Tank et al. (2022) は入力層の構造正則化によって依存構造を抽出した。一方、一般化 VAR（generalised VAR; GVAR）は、過去値を入力依存の係数で重み付けし、非線形な関係を係数として表す (Marcinkevičs and Vogt, 2021)。この係数表現で不要な入力を除くには、過去値に掛かる係数だけでなく、その入力が他の係数を変える経路も制御する必要がある。

そこで Gated Self-Explaining VAR（GSE-VAR）を提案する。対象・入力・ラグ別の共通ゲートで係数生成の入力と出力を制御し、各ゲートの選択確率に期待 L0 正則化を課し、DisARM で期待損失のロジット勾配を推定する。係数生成器とロジットは Adam で同時に更新する。

本研究の貢献は、非線形な係数表現と、ゲートの 0 による入力非依存性の判定を両立する設計にある。十分条件と符号解釈を示し、Lorenz96 の構造回復と線形 VAR の符号回復から評価する。さらに付録付録 A では、Favorita の販売系列を用いて、正解構造が未知の場合のモデル選択とカテゴリ間関係の記述を例示する。

2　関連研究

Neural Granger Causality（NGC）は対象別ネットワークの入力重みを正則化して入力経路を除去する (Tank et al., 2022)。GVAR は入力依存係数によって非線形な関係を表す (Marcinkevičs and Vogt, 2021)。提案手法は、係数値と係数生成入力を共通ゲートで制御し、入力除去と係数表現を結び付ける。提案手法では Bernoulli ゲートによって経路を選択し、対の標本を用いる DisARM(Dong et al., 2020) でロジット勾配を推定する。共通ゲートの設計により、二値選択と入力依存係数の表現を結び付ける。

3　問題設定

3.1　予測依存構造

p 変量時系列を $\boldsymbol{x}_t = (x_{1,t}, \ldots, x_{p,t})^\top$、最大ラグを K、利用する過去を $\boldsymbol{X}_t = (\boldsymbol{x}_{t-1}, \ldots, \boldsymbol{x}_{t-K})$ とする。本研究は二乗誤差による予測を扱うため、対象を条件付き平均 $\mu_i(\boldsymbol{X}_t) = \mathbb{E}[x_{i,t} \mid \boldsymbol{X}_t]$ とし、その近似を $\widehat{x}_{i,t} = h_i(\boldsymbol{X}_t)$ と書く。

定義 3.1 (条件付き平均に関する非因果性)**.** $\boldsymbol{X}_t^{(-j)}$ を、$\boldsymbol{X}_t$ から系列 j の全ラグを除いた情報とする。

$$\mathbb{E}[x_{i,t} \mid \boldsymbol{X}_t] = \mathbb{E}[x_{i,t} \mid \boldsymbol{X}_t^{(-j)}] \quad \text{a.s.} \tag{1}$$

が成立するとき、系列 j の過去は系列 i の条件付き平均の予測を改善しない。

式 (1) が対象とするのは条件付き平均の依存性である。これに対応するモデル上の性質として、他の入力を固定して系列 j の過去を変えても h_i が変わらないことを非因果性と定める。

3.2　線形 VAR と係数表現

線形 VAR の予測式は

$$\widehat{\boldsymbol{x}}_t = \boldsymbol{b} + \sum_{k=1}^{K} A_k \boldsymbol{x}_{t-k} \tag{2}$$

である。この形式では、全 k について $(A_k)_{ij} = 0$ なら系列 j の過去を含む項が全て消え、予測はその系列に依存しない。隣接行列は行を予測対象、列を入力とし、$\widehat{A}_{ij} = 1$ を $j \to i$ の向きと定める。

入力依存係数では係数生成を通じた依存も遮断する必要がある。

4　提案モデル

4.1　係数生成入力と出力の共通ゲート

予測対象 i、ラグ k に対し、入力系列ごとのゲート $\boldsymbol{g}_{ki} = (g_{ki1}, \ldots, g_{kip})^\top$ と、独立した係数生成器 $f_{\theta_{ki}} : \mathbb{R}^p \to \mathbb{R}^p$ を設ける。GSE-VAR を

$$\begin{aligned} \boldsymbol{v}_{ki,t} &= \boldsymbol{g}_{ki} \odot \boldsymbol{x}_{t-k}, \\ \boldsymbol{c}_{ki,t} &= \boldsymbol{g}_{ki} \odot f_{\theta_{ki}}(\boldsymbol{v}_{ki,t}), \end{aligned} \tag{3}$$

$$\widehat{x}_{i,t} = b_i + \sum_{k=1}^{K} \boldsymbol{c}_{ki,t}^\top \boldsymbol{x}_{t-k} \tag{4}$$

で定義する。$\odot$ は要素積、b_i は入力に依存しない切片、$\boldsymbol{c}_{ki,t}$ はゲートを含めた有効係数である。ゲートは時点によらない二値変数 $g_{kij} \in \{0, 1\}$ とする。

係数生成器は対象・ラグ別の多層パーセプトロン（MLP）とする。同一ラグ内の選択入力間の交互作用を表し、ラグ間は加算で集約する。

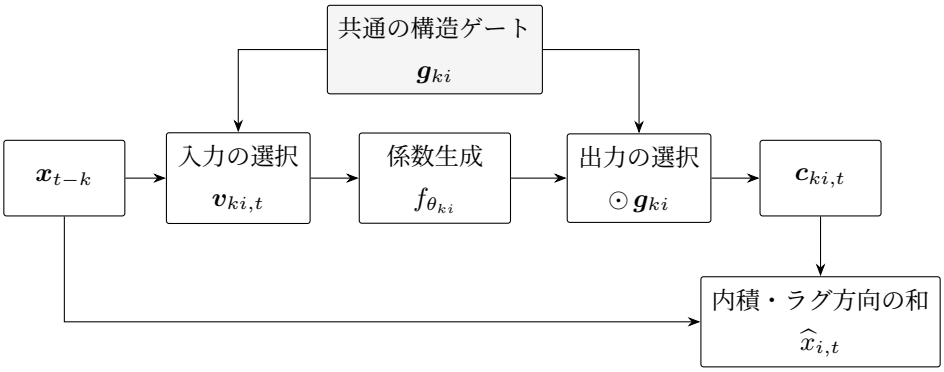


図 1　予測対象 i・ラグ k の計算経路。共通ゲートで係数生成の入力と出力を制御する。下側の過去値の経路も、係数側が 0 なら予測に寄与しない。

4.2　非因果性の十分条件

共通ゲートは直接の寄与と係数生成への入力を同時に除く。

命題 4.1 (入力系列への非依存性)**.** 式 (3)–(4) のモデルで、固定された i, j について $g_{1ij} = \cdots = g_{Kij} = 0$ なら、予測関数 h_i は系列 j の全ラグの値に依存しない。

証明. $\boldsymbol{e}_j$ を第 j 標準基底ベクトルとし、任意の $\delta_k \in \mathbb{R}$ によって $\widetilde{\boldsymbol{x}}_{t-k} = \boldsymbol{x}_{t-k} + \delta_k \boldsymbol{e}_j$ と入力を変更する。仮定 $g_{kij} = 0$ より、

$$\boldsymbol{g}_{ki} \odot \widetilde{\boldsymbol{x}}_{t-k} = \boldsymbol{g}_{ki} \odot \boldsymbol{x}_{t-k} + \delta_k g_{kij} \boldsymbol{e}_j = \boldsymbol{g}_{ki} \odot \boldsymbol{x}_{t-k}.$$

したがって式 (3) で生成される係数は変わらず、$\widetilde{\boldsymbol{c}}_{ki,t} = \boldsymbol{c}_{ki,t}$ かつ $c_{kij,t} = 0$ である。変更後の履歴を $\widetilde{\boldsymbol{X}_t}$ とすると、式 (4) から

$$\begin{aligned} h_i(\widetilde{\boldsymbol{X}_t}) - h_i(\boldsymbol{X}_t) &= \sum_{k=1}^{K} \boldsymbol{c}_{ki,t}^{\top} (\widetilde{\boldsymbol{x}}_{t-k} - \boldsymbol{x}_{t-k}) \\ &= \sum_{k=1}^{K} \delta_k c_{kij,t} = 0. \end{aligned}$$

δ_k は任意なので、予測関数は系列 j の全ラグに依存しない。 □

この命題は微分可能性によらず、学習後の固定ゲートに成立する。これに基づき、利用可能な入力経路のグラフを

$$\widehat{A}_{ij} = \mathbf{1}\{\exists k :\ g_{kij} \neq 0\} \tag{5}$$

と定める。$\widehat{A}_{ij} = 0$ はモデル内の非依存性を保証し、$\widehat{A}_{ij} = 1$ は利用可能な経路を表す。後者でも、生成器の出力が 0 となる場合や項が相殺される場合には、実際の依存が生じないことがある。

4.3　有効係数と符号の解釈

微分可能な点での予測の変化率は

$$J_{kij,t} := \frac{\partial \widehat{x}_{i,t}}{\partial x_{j,t-k}} = c_{kij,t} + \sum_{\ell=1}^{p} x_{\ell,t-k} \frac{\partial c_{ki\ell,t}}{\partial x_{j,t-k}} \tag{6}$$

となる。右辺第二項が係数の変化による効果を表すため、係数が一定なら $J_{kij,t} = c_{kij,t}$ となる。入力依存の場合には両者の対応を分析ごとに確かめることで、重みの方向と限界効果の関係を検討できる。各時点の予測への寄与は、入力値の符号も反映した積 $c_{kij,t} x_{j,t-k}$ で表される。

4.4　外生入力への拡張

外生変数を $\boldsymbol{u}_t$、利用可能な時点の集合を $\mathcal{K}_X$ とする。GSE-VARX では、内生・外生に別々の係数生成器と二値ゲートを設け、

$$\widehat{x}_{i,t} = b_i + \sum_{k=1}^{K} (\boldsymbol{c}_{ki,t}^{Y})^{\top} \boldsymbol{x}_{t-k} + \sum_{k \in \mathcal{K}_X} (\boldsymbol{c}_{ki,t}^{X})^{\top} \boldsymbol{u}_{t-k} \tag{7}$$

と予測する。各枝の係数は式 (3) と同様に入力・出力の共通ゲートで生成する。外生系列の値は予測対象に含めず、内生・外生の選択確率の和に別々の正則化係数を設定する。既知のカレンダー等には予測時点で利用可能な先行値も指定でき、各入力の系列名と実際のラグを保持する。

5　学習方法

5.1　予測損失と係数の平滑化

標本数 $N = T - K$、全有効係数 $C_t \in \mathbb{R}^{K \times p \times p}$ として、

$$\mathcal{L}(\theta, \boldsymbol{b}, g) = \frac{1}{Np} \sum_{t=K+1}^{T} \|\boldsymbol{x}_t - \widehat{\boldsymbol{x}}_t\|_2^2 + \gamma \mathcal{S}(\theta, g), \tag{8}$$

$$\mathcal{S}(\theta, g) = \frac{1}{(N-1)Kp^2} \sum_{t=K+1}^{T-1} \|C_{t+1} - C_t\|_F^2 \tag{9}$$

とする。θ は全係数生成器のパラメータである。第一項は 1 時点先の予測誤差、第二項は GVAR でも用いられる時間平滑化項であり、$\gamma \geq 0$ をその強さとする (Marcinkevičs and Vogt, 2021)。

5.2　Bernoulli ゲートと DisARM

経路 $m = (k, i, j)$ ごとに独立な

$$\pi_m = \sigma(\alpha_m), \qquad z_m \sim \mathrm{Bernoulli}(\pi_m) \tag{10}$$

を用い、式 (3) の g を z に置き換える。σ はロジスティック関数、α_m はロジットである。独立 Bernoulli 分布の積を q_α と書き、学習目的を

$$\mathcal{J}(\theta, \boldsymbol{b}, \alpha) = \mathbb{E}_{z \sim q_\alpha}[\mathcal{L}(\theta, \boldsymbol{b}, z)] + \lambda_0 \sum_{m} \pi_m + \frac{\rho}{2} \|\theta\|_2^2 \tag{11}$$

とする。第二項はラグ別経路の期待選択数 $\mathbb{E}[\sum_m \mathbf{1}\{z_m \neq 0\}]$ への罰則であり、期待損失と選択経路数を釣り合わせる。最後の項は係数生成器の重み減衰であり、ロジットと切片は対象から除く。

DisARM(Dong et al., 2020) では、共通乱数から得た二つのマスクの損失差で期待損失の勾配を推定する。成分ごとに独立な $u_m \sim U(0,1)$ から

$$z_m = \mathbf{1}\{u_m < \pi_m\}, \qquad \widetilde{z}_m = \mathbf{1}\{1 - u_m < \pi_m\} \tag{12}$$

を生成する。両者は同じ周辺分布を持ち、勾配推定に用いる各マスクは全時点で共有する。

さらに、対象別に生成器を分離しているため、$m = (k, i, j)$ の勾配には対象 i の損失だけを用いられる。二乗誤差と時間平滑化の対象別成分を ℓ_i とし、$\sum_i \ell_i = \mathcal{L}$ となるよう正規化すると、推定勾配は

$$\begin{aligned}\widehat{d}_m = \frac{1}{2}\left[\ell_i(\theta, \boldsymbol{b}, z) - \ell_i(\theta, \boldsymbol{b}, \widetilde{z})\right](1 - 2\widetilde{z}_m)\mathbf{1}\{z_m \neq \widetilde{z}_m\}\sigma(|\alpha_m|) \\ + \lambda_0 \pi_m(1 - \pi_m)\end{aligned} \tag{13}$$

となる。第一項で期待損失の勾配を推定し、第二項で期待 L0 罰則の解析的な微分を加える。ロジットにはこの勾配を、係数生成器と切片には二損失の平均の勾配を用い、Adam で同時に更新する。学習後は $\widehat{g}_m = \mathbf{1}\{\pi_m \geq 0.5\}$ でゲートを固定することで、命題 4.1 に基づいて非因果性を判定できる。

VARX でも内生・外生両枝のマスク対を同じ更新前パラメータで評価し、両方のロジットと係数生成器を 1 回の Adam 更新で学習する。内生・外生の期待 L0 罰則にはそれぞれ λ_Y, λ_X を用いる。

6 実験方法

6.1 評価目的と共通設定

提案モデルの構造選択と係数解釈を検証するため、Lorenz96 で構造回復、線形 VAR で符号回復を評価する。系列長 $T \in \{250, 500\}$ には同じ生成系列の先頭区間を用い、訓練区間で標準化する。評価する関係を変数間に限定し、自己辺は採点から除外する。

係数生成器は隠れ層 1 層の MLP とする。独立な予備 3 系列で幅 $\{8, 32\}$ を比較し、各条件で選ばれた幅 8 を用いる。基準は Lorenz96 では平均 F1、線形 VAR では正・負の balanced accuracy（BA）の平均である。構造回復では正則化 10 候補から平均 F1 が最大の候補を選び、同点なら平均選択辺数、尺度の小さい順に選ぶ。

正則化尺度 s を $\lambda_0 = s/(Kp^2)$ へ換算する。係数生成器の学習率は 0.003、ロジットの学習率は 0.03、時間平滑化係数は 0.01、重み減衰係数は 0.001、初期選択確率は 0.5 とする。全標本をまとめて 10,000 エポック学習した最終モデルを評価する。Lorenz96 では系列ごとに学習初期値を変え、線形 VAR では固定する。

6.2 Lorenz96 における構造回復

NGC で用いられる Lorenz96 系 (Tank et al., 2022)

$$\frac{dx_i(s)}{ds} = (x_{i+1}(s) - x_{i-2}(s))\, x_{i-1}(s) - x_i(s) + F \tag{14}$$

から、周期境界条件の下で時系列を生成する。変数数 $p = 20$、外力 $F = 40$、観測間隔は約 0.05 とする。初期 1000 点を除き、標準偏差 0.1 の独立な正規観測雑音を加える。最大ラグ $K = 5$ とし、生成した 5 系列を評価する。データと学習初期値は手法間で対応させる。

参照構造は微分方程式の直接依存とし、自己辺を除くと $i+1, i-1, i-2$ から i への 60 辺である。間接依存と観測雑音を含む離散系列から、この構造の回復を評価する。

GSE-VAR の正則化尺度は $\{0, 0.3, 1, 2, 3, 4, 5, 7, 10, 30\}$ の 10 候補とする。予備評価で選んだ尺度は $T = 250, 500$ の順に 4、5 である。NGC の採用値は 0.5、0.4 で、各系列長の 10 候補を独立に学習する。

6.3 線形 VAR 過程における符号回復

GVAR の符号評価に用いられる 4 変量の生成法 (Marcinkevičs and Vogt, 2021) に従い、$\boldsymbol{x}_t = (x_t, w_t, y_t, z_t)^\top$ を

$$\boldsymbol{x}_t = A\boldsymbol{x}_{t-1} + \boldsymbol{\varepsilon}_t, \quad A = \begin{pmatrix} a_1 & 0 & 0 & 0 \\ a_3 & a_2 & 0 & 0 \\ 0 & a_5 & a_4 & 0 \\ 0 & a_7 & a_8 & a_6 \end{pmatrix}, \quad \boldsymbol{\varepsilon}_t \sim N(0, 0.4^2 I) \tag{15}$$

から生成する。各 a_r は、等確率で選ぶ区間 $[-0.8, -0.2]$ または $[0.2, 0.8]$ の一様分布に従う。下三角行列の対角の絶対値が 1 未満なので過程は安定である。初期値 0、最大ラグ $K = 1$ とし、係数を変えた 10 系列を評価する。非自己の真辺は 4 本であり、標準化後も正解の符号は変わらない。

正則化尺度は $\{0, 0.01, 0.03, 0.1, 0.3, 1, 3, 10, 30\}$ の 9 候補とする。採用尺度は $T = 250, 500$ の順に、GSE-VAR が 0.3、0.1 である。

6.4 比較手法と評価指標

構造回復では NGC の cMLP、GVAR、線形 VAR を比較対象とする。符号回復では、符号付き係数を持つ GVAR と線形 VAR を用いる。NGC は隠れ層 1 層・幅 100、階層型グループ正則化を用い、5000 エポック学習する。GVAR は隠れ層 2 層・幅 50、1000 エポックとし、二値化には原系列と逆時間系列の推定構造の一致を用いる選択手順を適用する (Tank et al., 2022; Marcinkevičs and Vogt, 2021)。線形 VAR 実験の GVAR には、疎性係数 0.2、平滑化係数 0.5 を用いる。Lorenz96 の GVAR は独立な予備系列で設定を選ぶ。

線形 VAR は切片付き最小二乗法で推定し、系列の全ラグを除く制約に対する F 検定を行う。Benjamini–Hochberg 法を水準 0.05 で適用し、二値グラフを得る (Benjamini and Hochberg, 1995)。

構造回復は、採用した設定で得られるグラフと、設定を変えた際の選択結果の両面から評価する。前者には適合率、再現率、F1 と辺選択頻度を用い、予備探索で採用した正則化強度の結果を集計する。GSE-VAR はゲートがいずれかのラグで非 0 となる辺、NGC は入力重みグループが非 0 となる辺を選択されたものとする。

後者には PR 曲線の面積（AUPRC）を用いる。GSE-VAR と NGC では正則化 10 候補を大から小へ変え、GVAR では $S_{ij} = \max_k \mathrm{median}_t\, |c_{kij,t}|$、線形 VAR では負の F 検定 p 値の閾値を変える。得られた適合率と再現率の隣接点間を台形則で積分するため、前 2 手法は正則化による構造変化、後 2 手法は単一モデルでの選択結果を評価する。選択辺がない場合の適合率は 1 と定義し、観測した再現率の範囲のみを積分する。

符号回復では、選択辺の係数の時点中央値の符号を用い、未選択辺は 0 とする。この符号から正辺・負辺をそれぞれ陽性とする BA を求め、その平均を主指標とする。BA は感度と特異度の平均で

あり、その他の変数対はそれぞれ陰性となる。片側のクラスがない系列は欠測とし、各指標を系列ごとの値、平均、標本標準偏差で示す。

7　実験結果

7.1　Lorenz96 における構造回復

表 1 に構造回復の結果を示す。$T = 500$ では GSE-VAR が全 5 系列で 60 真辺を過不足なく選択した。

表 1　Lorenz96 の構造回復。5 系列の平均 ± 標本標準偏差。PR 面積は観測点間の台形積分、F1 と辺数は独立な予備探索で選んだ設定の値である。自己辺を除外し、各条件・指標の最大平均値を太字とした。

T	手法	AUPRC	F1	辺数
250	GSE-VAR	**0.9998** ± 0.0004	**0.997** ± 0.007	60.4
	NGC	0.5233 ± 0.0589	0.454 ± 0.053	44.0
	GVAR	0.8217 ± 0.0689	0.616 ± 0.094	35.6
	線形 VAR	0.4103 ± 0.0913	0.226 ± 0.125	15.4
500	GSE-VAR	**1.0000** ± 0.0000	**1.000** ± 0.000	60.0
	NGC	0.7434 ± 0.0336	0.628 ± 0.070	34.4
	GVAR	0.9941 ± 0.0044	0.866 ± 0.044	48.2
	線形 VAR	0.6430 ± 0.0622	0.478 ± 0.053	26.8

図 2 では、GSE-VAR が高い適合率を保ちながら真辺を選択している。$T = 250$ の平均 AUPRC は 0.9998、$T = 500$ では 1.0000 となった。

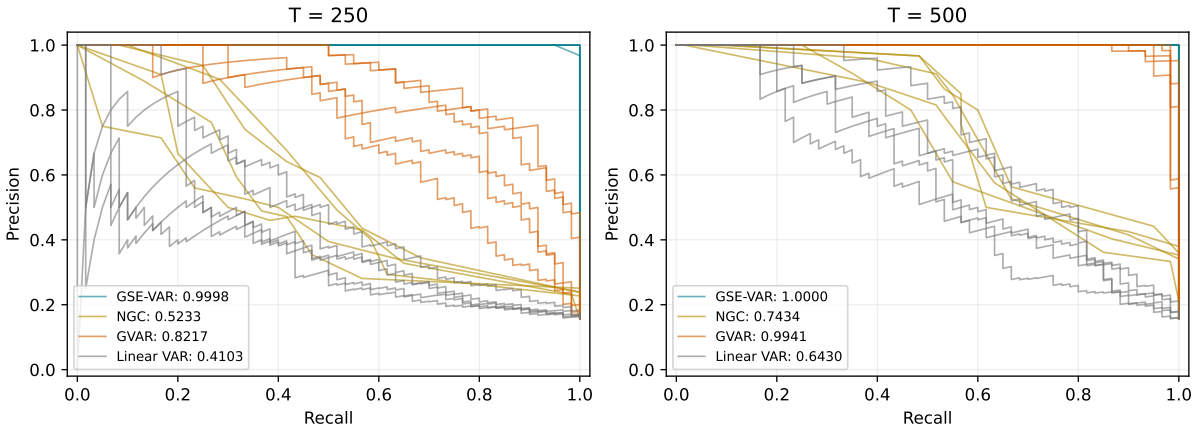


図 2　Lorenz96 の PR 曲線。各条件の 5 系列を重ねた。GSE-VAR と NGC は正則化 10 候補で選択された辺、GVAR と線形 VAR はそれぞれ係数強度と負の p 値に対する閾値を変えて求める。線は観測点間を結び、凡例は平均 AUPRC を示す。

図 3 で選択頻度を示す。GVAR の $T = 500$ では AUPRC が高くても採用グラフには見落としが

残り、順位評価と固定グラフの回復は一致しない。

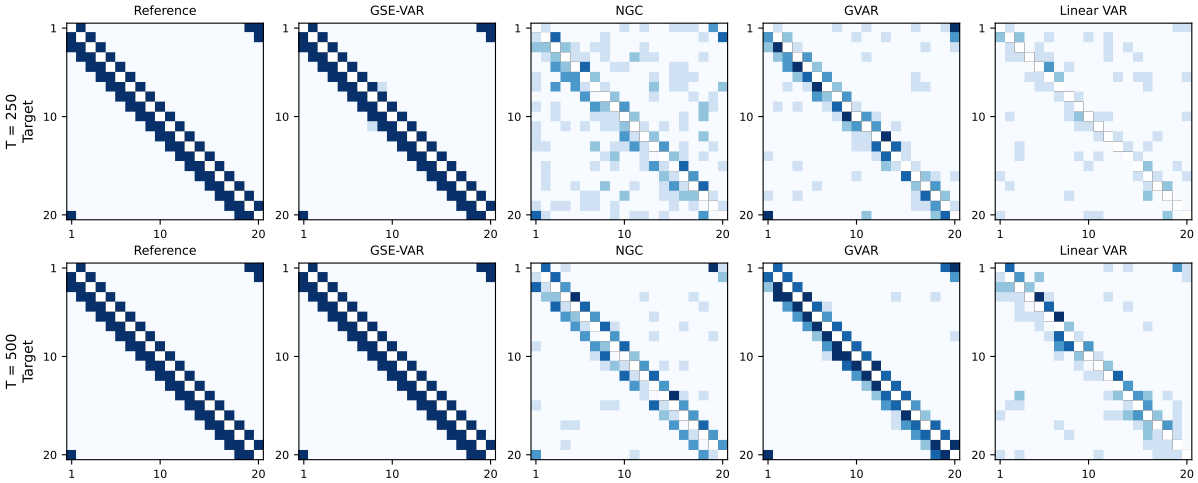


図 3　Lorenz96 の参照構造と各手法の辺選択頻度。行は予測対象、列は入力系列であり、色は 5 回の実験で辺が選択された割合を示す。上段は $T = 250$、下段は $T = 500$。自己辺は灰色とした。

7.2　線形 VAR 過程における符号回復

表 2 では、両系列長とも線形 VAR の平均符号 BA が最も高い。GSE-VAR は $T = 250, 500$ でそれぞれ 0.900、0.975 となり、GVAR を上回った。

表 2　線形 VAR の符号回復。10 系列の平均 ± 標本標準偏差。正・負の BA はそれぞれの符号を陽性として算出し、その平均を主指標とする。各条件・指標の最大平均値を太字とした。

T	手法	BA_{pos}	BA_{neg}	平均符号 BA
250	GSE-VAR	0.908 ± 0.169	0.892 ± 0.167	0.900 ± 0.129
	GVAR	0.883 ± 0.172	0.877 ± 0.178	0.880 ± 0.157
	線形 VAR	$\mathbf{0.995} \pm 0.014$	$\mathbf{0.990} \pm 0.021$	$\mathbf{0.993} \pm 0.012$
500	GSE-VAR	0.975 ± 0.079	0.975 ± 0.079	0.975 ± 0.053
	GVAR	0.895 ± 0.172	0.912 ± 0.178	0.903 ± 0.140
	線形 VAR	$\mathbf{0.995} \pm 0.014$	$\mathbf{0.990} \pm 0.020$	$\mathbf{0.993} \pm 0.011$

図 4 に全 12 非自己係数を示す。GSE-VAR では符号が一致しても係数が大きく変動する場合がある。

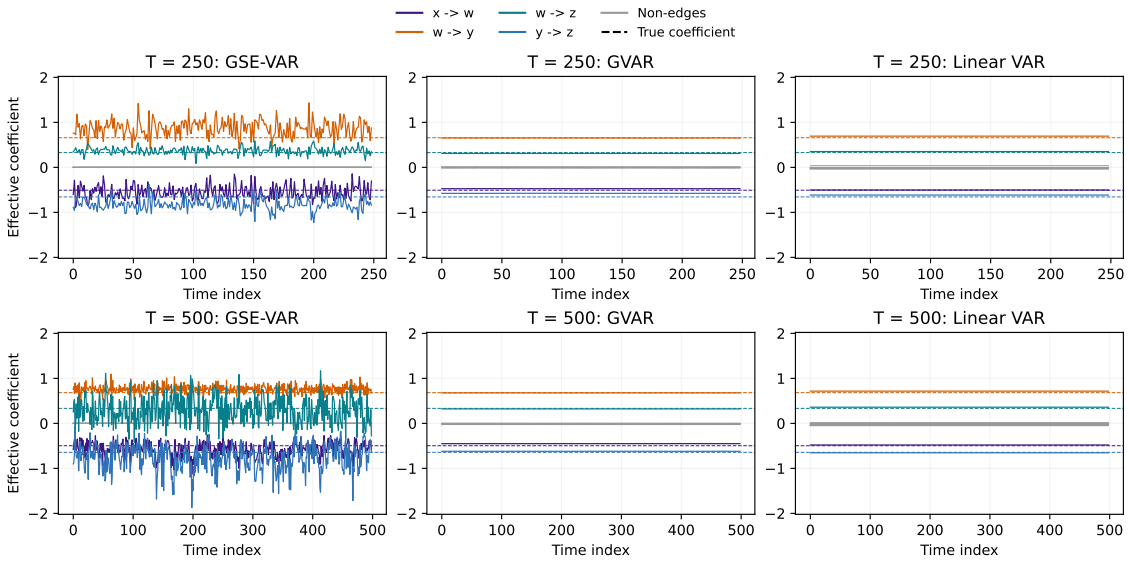


図 4　線形 VAR の全 12 非自己係数。上段は $T = 250$、下段は $T = 500$ の第 1 系列。左から GSE-VAR、GVAR、線形 VAR。色付き実線は 4 真辺、灰色実線は 8 非辺、破線は標準化後の真値を示す。全 6 パネルの縦軸を共通とし、平滑化や値の切り捨ては行っていない。

8　限界

命題 4.1 はモデル内の入力非依存性を保証する一方、真の構造の回復は変数集合、ラグ数、表現力、標本数に依存し、相関する入力が予測を代替すれば選択辺も変わり得る。Lorenz96 で確認したのは、独立した予備系列の正解構造で設定を選んだ条件での性能である。未知構造で同等の回復を実現できるとは限らず、予測損失の小ささだけでは選択グラフの正しさを確認できない。

Favorita では単一店舗の 12 カテゴリと一つの学習初期値に対象が限られる。販促、価格、祝日、在庫、来店者数などを明示的に条件付けていないため、選択辺が共通要因を反映する可能性がある。曜日調整後も残る季節性や非定常性も推定に影響する。初期値や店舗を変えた再現性、外部情報を加えた構造の安定性は、本稿の結果からは判断できない。

有効係数とヤコビアンの対応は観測状態上で調べられ、介入効果の同定には追加の因果仮定を要する。対象・ラグ別の生成器が表す交互作用の範囲は同一ラグ内に限られる。

9　結論

入力依存係数と入力経路の厳密な除去を両立する GSE-VAR を定式化し、共通の二値ゲートによる推定モデル上の非因果性の十分条件を示した。Bernoulli ゲートの選択確率に期待 L0 正則化を課し、DisARM による不偏勾配推定と Adam で学習する。Lorenz96 では系列長 500 の全 5 系列で参照構造を回復し、線形 VAR では同じ系列長の平均符号 BA が 0.975 となった。Favorita では予測依存を 7 本の経路として記述できた。外生入力を別枝で扱う VARX にも同じ学習方法を適用できる。

付録 A　Favorita 販売データへの適用

A.1　分析目的とデータ

エクアドルの小売企業 Corporación Favorita の販売データ (Kaggle, 2021) を用いる。訓練中に全 12 カテゴリの正販売日の割合が 80% 以上で、各系列に変動がある店舗のうち最小番号の店舗 1（Quito）を選んだ。対象カテゴリは図 5 に示す。

2016 年 7 月 1 日から 2017 年 2 月 28 日を訓練、2017 年 3 月 1 日から 4 月 30 日を検証、5 月 1 日から 8 月 15 日をテストとする。欠測の 2016 年 12 月 25 日は補間せず、7 日ラグの窓全体が観測される場合のみ用いる。訓練は欠測前後で区切り、検証 61 時点、テスト 107 時点を評価する。

販売量を $y_{j,t}$、曜日を $d(t)$ として、入力を

$$x_{j,t} = \frac{\log(1 + y_{j,t}) - m_{j,d(t)}}{s_j} \tag{16}$$

へ変換する。$m_{j,d}$ は訓練区間における曜日別の対数販売量の平均、s_j は曜日平均を除いた訓練残差の標準偏差である。訓練で求めた変換を検証・テストに固定し、外生変数は入力しない。

A.2　候補設定と検証による選択

GSE-VAR、NGC の cMLP(Tank et al., 2022)、線形 VAR(SGL) を比較し、最大ラグを 7 日とする。GSE-VAR は隠れ層 1 層・幅 8、平滑化係数 0.01、重み減衰 0.001、初期選択確率 0.5 とする。尺度 $s \in \{0, 0.3, 1, 2, 3, 4, 6, 10, 20, 40\}$ を $\lambda_0 = s/(7 \times 12^2)$ に換算し、係数・ゲート学習率の組 $(0.003, 0.03), (0.001, 0.01), (0.001, 0.03)$ と合わせて 30 候補を比較する。cMLP は隠れ層 1 層・幅 100、L2 係数 0.01 とし、階層グループ正則化係数 $\{0, 0.001, 0.003, 0.01, 0.03, 0.1, 0.3, 0.5, 1, 10\}$ と学習率 $\{0.01, 0.003\}$ の 20 候補を近接勾配法で学習する。両ニューラルモデルは最大 5000 エポック、初期 200 エポックまでは 20、その後は 100 エポックごとに検証する。線形 VAR は L1 係数 10^{-4}、グループ係数 $\{0, 10^{-5}, 3 \times 10^{-5}, 10^{-4}, 3 \times 10^{-4}, 10^{-3}, 0.003, 0.01, 0.03, 0.1\}$ の 10 候補とする。検証 MSE 最小の候補・チェックポイントを採用し、同点ではエポック数、候補番号の順で選ぶ。

採用された GSE-VAR は $s = 2$、学習率の組 $(0.003, 0.03)$、1400 エポック、cMLP は正則化係数 0.1、学習率 0.01、5000 エポックであり、線形 VAR のグループ係数は 0.01 であった。検証最良モデルを再推定せずテストで評価する。学習初期値は 42 とする。

A.3　予測誤差と選択構造

目的変数 j のテスト MSE と、全変数をまとめた MSE を

$$\mathrm{MSE}_j = \frac{1}{N_{\mathrm{test}}} \sum_{t} (\widehat{x}_{j,t} - x_{j,t})^2, \qquad \mathrm{MSE} = \frac{1}{12} \sum_{j=1}^{12} \mathrm{MSE}_j \tag{17}$$

と定める。全体の RMSE は $\sqrt{\mathrm{MSE}}$ である。表 3 のとおり、GSE-VAR、cMLP、線形 VAR のテスト MSE はそれぞれ $0.4620, 0.4727, 0.4703$、ラグを統合した非自己辺数は 7 本、39 本、66 本であっ

た。GSE-VAR は三手法の中で最も低いテスト MSE と少ない選択辺数を示した。

表 3　Favorita のモデル選択とテスト評価。誤差は標準化尺度、辺数は自己辺を除く。各手法 1 モデルの値である。

手法	検証 MSE	テスト MSE	テスト RMSE	非自己辺数
GSE-VAR	0.4533	0.4620	0.6797	7
cMLP	0.4617	0.4727	0.6875	39
線形 VAR(SGL)	0.4810	0.4703	0.6858	66

図 5 では調理済食品と魚介の誤差が大きい。GSE-VAR は酒類で線形 VAR より低い MSE を示す一方、冷凍食品では線形 VAR が低い。

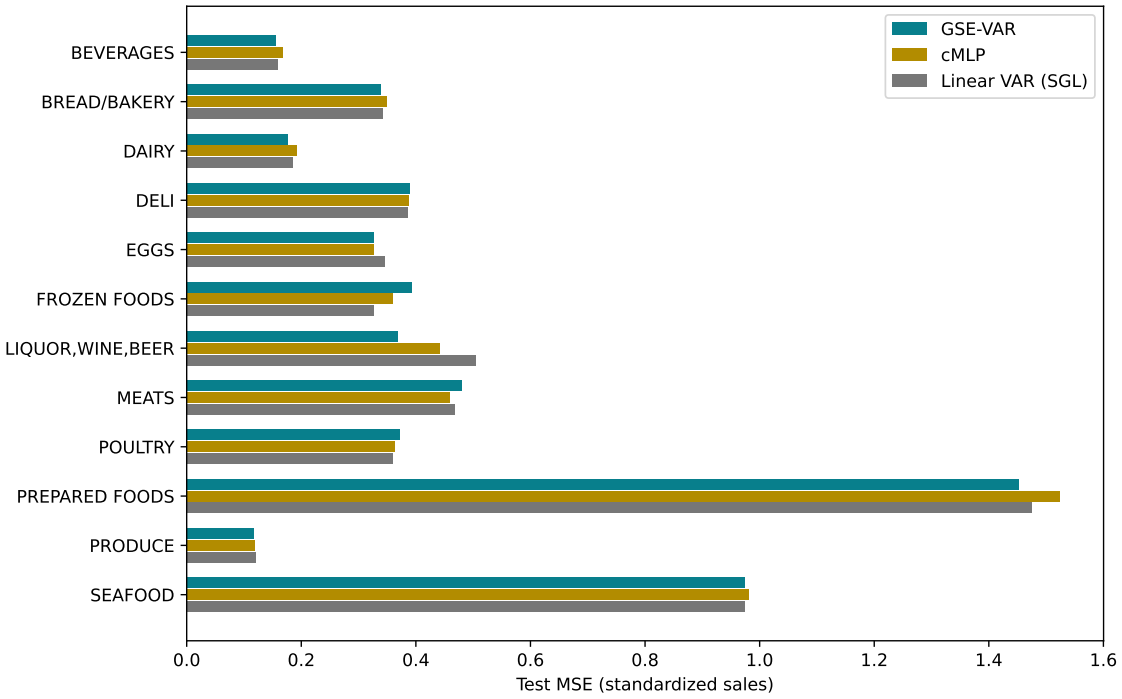


図 5　目的変数別テスト MSE。三手法で同一の 107 時点を評価し、曜日調整した対数販売量の標準化尺度で比較する。

A.4　カテゴリ間の関係の記述

図 6 に三手法の選択構造、図 7 に GSE-VAR の 7 本の非自己選択経路を示す。GSE-VAR の各辺はいずれも一つのラグで構成され、モデル内で利用可能な予測経路を表す。

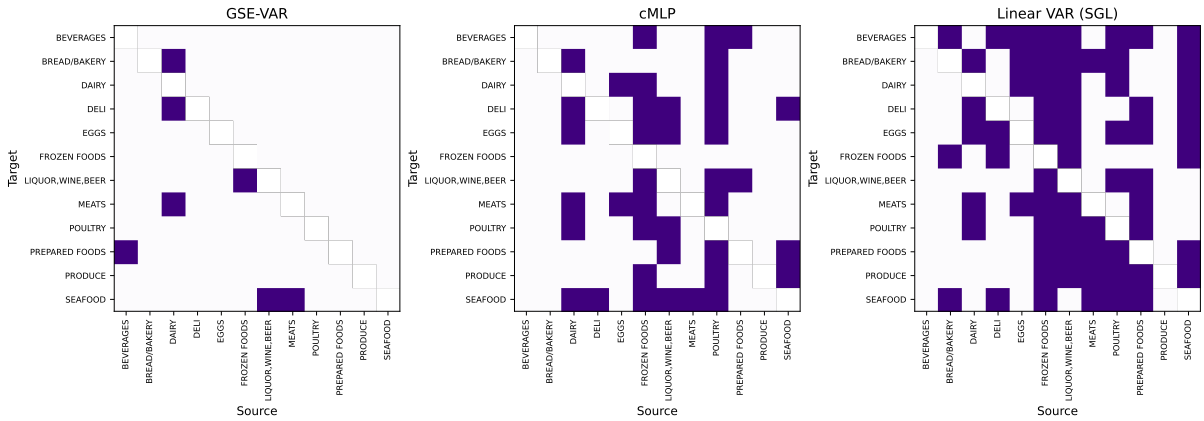


図 6　Favorita のラグ統合選択構造。左から GSE-VAR、cMLP、線形 VAR。行が予測対象、列が入力で、紫色は少なくとも一つのラグが選択された変数対を示す。cMLP は入力層の非零重み、線形 VAR は非零係数から辺を抽出し、自己辺は表示から除いた。

係数の符号はテスト時点の 80% 以上で正なら正、80% 以上で負なら負、他は混在とする。酒類から魚介は混在、残る 6 経路は正であった。

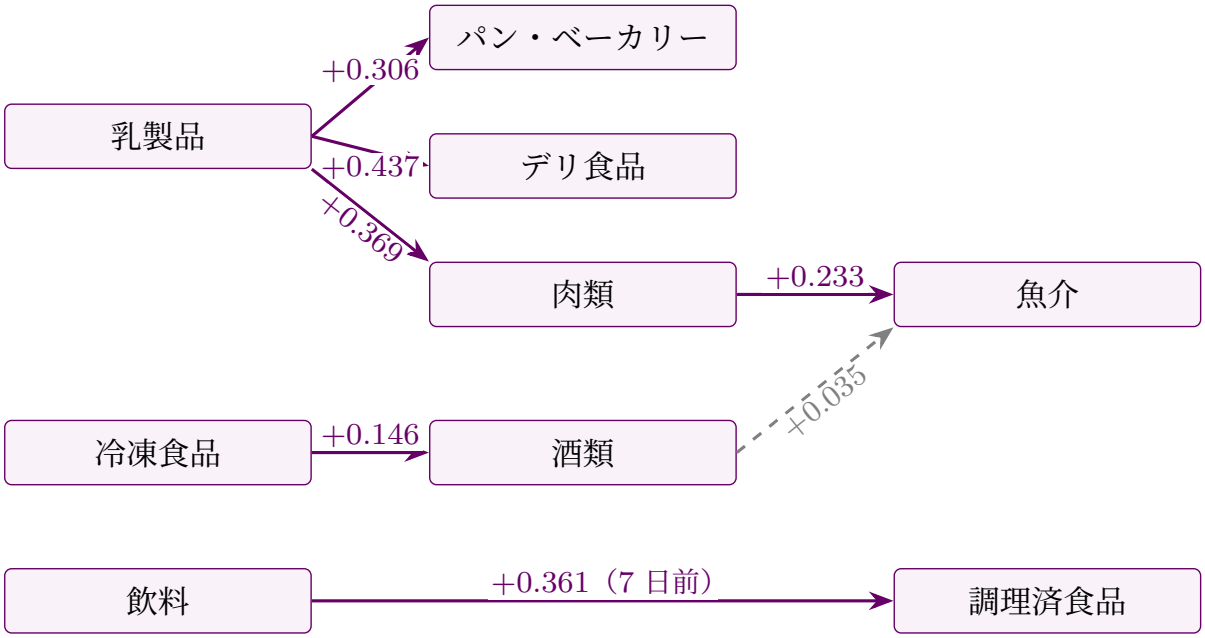


図 7　GSE-VAR の非自己選択経路。矢印は入力から予測対象への向きを示す。数値は標準化尺度の 107 テスト時点における係数の中央値。飲料から調理済食品は 7 日前、他は 1 日前の入力であり、破線は符号が混在する経路を表す。

係数は予測式上の重みを表す。図 7 のように、カテゴリ名・ラグ・係数を組み合わせることで、予測を担う経路を具体的に検討できる。局所感度との対応には式 (6) を用い、共通する購買動向や販促の影響は第 8 節の課題として扱う。

参考文献

Y. Benjamini and Y. Hochberg. Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995. doi: 10.1111/j.2517-6161.1995.tb02031.x.

Z. Dong, A. Mnih, and G. Tucker. DisARM: An antithetic gradient estimator for binary latent variables. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL `https://arxiv.org/abs/2006.10680`.

C. W. J. Granger. Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3):424–438, 1969. doi: 10.2307/1912791.

Kaggle. Store sales — time series forecasting: Data, 2021. URL `https://www.kaggle.com/competitions/store-sales-time-series-forecasting/data`.

R. Marcinkevičs and J. E. Vogt. Interpretable models for Granger causality using self-explaining neural networks. In *International Conference on Learning Representations*, 2021. URL `https://arxiv.org/abs/2101.07600`.

A. Tank, I. Covert, N. Foti, A. Shojaie, and E. B. Fox. Neural Granger causality. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(8):4267–4279, 2022. doi: 10.1109/TPAMI.2021.3065601.